

موضوع : پروژه نهایی درس یادگیری ماشین

نام و نام خانوادگی : عبدالحسین منیعی
شماره دانشجویی : 4021190013

چکیده - در این پروژه، مجموعه داده تشخیص فعالیت انسان (Human Activity Recognition - HAR) مورد تحلیل و ارزیابی قرار گرفت. هدف، طبقه‌بندی ۶ نوع فعالیت فیزیکی (شامل راه رفتن، بالا/پایین رفتن از پله، نشستن، ایستادن و دراز کشیدن) با استفاده از ۵۶۱ ویژگی استخراج‌شده از حسگرهای موبایل است. برای دستیابی به بهترین عملکرد، آزمایش‌ها در دو فاز انجام شد: فاز اول تفکیک کلی فعالیت‌ها به دو دسته «ساکن» و «پویا» که منجر به دقت ۱۰۰٪ گردید، و فاز دوم تفکیک دقیق تمام ۶ فعالیت. پس از پیش‌پردازش و نرمال‌سازی، از الگوریتم PCA جهت کاهش ابعاد (با حفظ ۹۵٪ واریانس) استفاده شد. سپس عملکرد الگوریتم‌های رگرسیون لجستیک (Logistic Regression) و ماشین بردار پشتیبان SVM با کرنل RBF مقایسه گردید. نتایج نشان داد که مدل SVM در حالت چندکلاسه با دقت حدود ۹۶٪ عملکرد بسیار مطلوبی دارد. همچنین الگوریتم خوشه‌بندی K-Means به صورت بدون ناظر اجرا شد تا ساختار ذاتی داده‌ها بررسی شود. نمودارهای منحنی یادگیری (Learning Curve) نشان‌دهنده برازش مناسب (Good Fit) مدل‌ها می‌باشد.

۲. استراتژی کاهش ابعاد (PCA)

به منظور کاهش پیچیدگی محاسباتی و حذف ویژگی‌های همبسته، الگوریتم PCA اجرا شد:

- تحلیل بصری: کاهش به ۳ بُعد جهت رسم نمودار سه‌بعدی و اثبات تفکیک‌پذیری کلاس‌های ساکن و پویا.
- تحلیل مدل‌سازی: حفظ ۹۵٪ واریانس کل داده‌ها که منجر به کاهش ویژگی‌ها از ۵۶۱ به حدود ۱۰۲ مولفه شد.

۳. پیکربندی مدل‌ها

- رگرسیون لجستیک: با حل گر $lbfgs$ و استراتژی چندجمله‌ای $(Multinomial)$ برای پشتیبانی از ۶ کلاس.
- ماشین بردار پشتیبان (SVM) با کرنل RBF جهت جداسازی غیرخطی. پارامتر جریمه $C = 1.0$ انتخاب شد که تعادل مناسبی بین بایاس و واریانس ایجاد کرد.
- خوشه‌بندی: الگوریتم $K-Means$ با $K = 6$ و مقداردهی اولیه تصادفی.

1- مقدمه

تشخیص خودکار فعالیت‌های انسانی با استفاده از ابزارهای پوشیدنی، کاربردهای وسیعی در حوزه سلامت و مراقبت از سالمندان دارد. چالش اصلی در این داده‌ها، شباهت سیگنالی برخی فعالیت‌ها (مانند نشستن و ایستادن) و ابعاد بالای ویژگی‌هاست. در این پژوهش، از مجموعه داده استاندارد HAR شامل ۱۰,۲۹۹ نمونه (۷۳۵۲ آموزش و ۲۹۴۷ آزمون) استفاده شده است. طبق الزامات پروژه، مراحل زیر انجام پذیرفت:

1. پیش‌پردازش و مدیریت داده‌های پرت.
2. کاهش ابعاد با PCA.
3. مدل‌سازی نظارت‌شده SVM و رگرسیون لجستیک و بررسی بیش‌برازش/کم‌برازش.
4. مدل‌سازی بدون ناظر $(K-Means)$.
5. تحلیل توابع هزینه و مقایسه نتایج.

1-2- معادلات ریاضی

۱. پیش‌پردازش داده‌ها (نرمال‌سازی)

در مرحله اول، برای اینکه ویژگی‌ها هم‌مقیاس شوند (میانگین ۰ و انحراف معیار ۱)، از فرمول $Z-Score$ استفاده شد:

$$z = \frac{x - \mu}{\sigma}$$



- x : مقدار اولیه ویژگی
- μ : میانگین ویژگی ($Mean$)

2- روش تهیه

۱. پیش‌پردازش و نرمال‌سازی


از آنجا که الگوریتم SVM بر مبنای فاصله اقلیدسی و PCA بر مبنای واریانس عمل می‌کنند، یکسان‌سازی مقیاس ویژگی‌ها حیاتی است. بدین منظور از روش $StandardScaler$ استفاده شد تا تمامی ۵۶۱ ویژگی دارای میانگین صفر و انحراف معیار یک شوند. این عمل همچنین اثر داده‌های پرت ($Outliers$) را تعدیل نمود.

Plot 6: 3D Visualization of Dimension Reduction (Separation of Static vs Dynamic)



نمایش داده ها بدون در نظر گرفتن لیبل ها توسط خوشه بندی K-means

Plot 4: Cost Function per Epoch (SGD Training)



مقدار تابع هزینه برای هر دور اجرا

• σ انحراف معیار (Standard Deviation)

۲. کاهش ابعاد (PCA)

الگوریتم PCA با محاسبه مقادیر ویژه ($Eigenvalues$) و بردارهای ویژه ($Eigenvectors$) ماتریس کواریانس کار می کند. اگر ماتریس کواریانس را Σ بنامیم:

$$\Sigma = \frac{1}{m} \sum_i^m (x^i)(x^i)^T$$

هدف PCA پیدا کردن ماتریس تبدیل U است که واریانس را ماکزیمم کند.

۳. رگرسیون لجستیک ($Logistic Regression$)

این الگوریتم از تابع سیگموئید ($Sigmoid$) برای تخمین احتمال استفاده می کند:

$$h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$$

تابع هزینه ($Cost Function$) که در نمودارها رسم کردیم ($Log Loss$)، به صورت زیر محاسبه می شود:

$$J(\theta) = -\frac{1}{m} \sum_i^m [(y^i \log(h_{\theta}(x^i)) + (1 - y^i) \log(1 - h_{\theta}(x^i)))] + \frac{\lambda}{2m} \sum_{j=1}^n \theta_j^2$$

(جمله آخر مربوط به رگولایزاسیون $L2$ است که به طور پیش فرض در $sklearn$ فعال است).

۴. ماشین بردار پشتیبان (SVM) چون از کرنل RBF (تابع پایه شعاعی) استفاده کردیم، فرمول محاسبه شباهت بین دو نمونه x و l ($Landmark$) به صورت زیر است:

$$K(x, l) = \exp\left(-\frac{\|x - l\|^2}{2\sigma^2}\right) = \exp(-\gamma\|x - l\|^2)$$

هدف SVM پیدا کردن ضرایب w و b است که تابع زیر را مینیمم کند (C) پارامتر جریمه است):

$$\min_{w, b} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^m \xi_i$$

۵. خوشه بندی ($K-Means$) تابع هدف در $K-Means$ به آن $Inertia$ گفته می شود و در کد مقدار آن را چاپ کردیم، مجموع مربعات فاصله نقاط تا مرکز خوشه μ_c است:


$$J(c, \mu) = \sum_{i=1}^m \|x^{(i)} - \mu_{c(i)}\|^2$$

2-2- نتایج و تحلیل نمودارها

الف) تحلیل فاز اول: تفکیک پذیری فیزیکی ساکن VS پویا در ابتدا، توانایی مدل در تفکیک وضعیت های «ساکن» (نشسته، ایستاده، خوابیده) از «پویا» (انواع راه رفتن) بررسی شد.

ب) تحلیل فاز دوم: طبقه‌بندی ۶ کلاس در این مرحله، تمام ۶ فعالیت مورد ارزیابی قرار گرفتند


ماتریس درهم‌ریختگی این نمودار نقاط ضعف و قوت مدل *SVM* را نشان می‌دهد.




قطر اصلی ماتریس اعداد بزرگی دارد که نشان‌دهنده تشخیص صحیح است. تفکیک عالی: فعالیت «دراز کشیدن» (*Laying*) تقریباً بدون خطا تشخیص داده شده است.

چالش اصلی: مقداری تداخل بین «نشستن» (*Sitting*) و «ایستادن» (*Standing*) مشاهده می‌شود. دلیل علمی این خطا، شباهت الگوی شتاب‌سنج در هر دو حالت (سکون کامل دست و بدن) است.

بررسی منحنی یادگیری (*Learning Curve*) - تشخیص بیش‌برازش به منظور بررسی وضعیت برازش مدل رگرسیون لجستیک، نمودار زیر ترسیم شد.



خطوط دقت آموزش (*Training*) و اعتبارسنجی (*Validation*) در مقادیر بالا (حدود ۹۵٪) به هم همگرا شده‌اند. فاصله کم بین این دو خط نشان می‌دهد که مدل دچار *High Variance* (بیش‌برازش) نیست و دقت بالا نشان می‌دهد که دچار *High Bias* (کم‌برازش) نیز نمی‌باشد. مدل در وضعیت *Good Fit* است. نمودار تابع هزینه (*Cost Function*) روند کاهش خطای مدل در طول فرآیند یادگیری در نمودار زیر نمایش داده شده است.



مقایسه الگوریتم لجستیک و *SVM* برای دو کلاس ایستا و پویا

SVM Analysis


SVM Accuracy: 0.9997

SVM Cost: 0.0034


Logistic Regression Analysis

Logistic Accuracy: 0.9997



Logistic Cost (Log Loss): 0.0037




تفکیک داده‌ها توسط الگوریتم *SVM*




خوشه‌بندی بدون ناظر (*K-Means*)



تابع هزینه (*Log Loss*) با روندی نزولی و هموار کاهش یافته است که نشان‌دهنده همگرایی صحیح الگوریتم گرادینان کاهشی و انتخاب مناسب پارامتر نرخ یادگیری است.



مقایسه مدل‌ها در حالت 6 کلاس



هر دو مدل *Logistic Regression* و *SVM* عملکردی بسیار نزدیک (بالای ۹۴٪) داشتند، اما *SVM* با اختلاف جزئی در تفکیک کلاس‌های پیچیده (مثل پله‌ها) بهتر عمل کرد.

3- نتیجه‌گیری

در این پروژه، الگوریتم‌های یادگیری ماشین بر روی مجموعه داده *HAR* پیاده‌سازی شد. نتایج نشان داد که:

تفکیک‌پذیری فعالیت‌های انسانی به دو دسته کلی ساکن و پویا با دقت ۱۰۰٪ قابل تفکیک هستند.

عملکرد الگوریتم‌ها: مدل *SVM* با کرنل *RBF* توانست با دقت تقریبی ۹۶٪، تمامی ۶ فعالیت را شناسایی کند. خطای جزئی موجود ناشی از شباهت فیزیکی شدید بین حالت نشستن و ایستادن است. نقش *PCA*: کاهش ابعاد نه تنها سرعت پردازش را افزایش داد، بلکه با حذف نویز، به جلوگیری از بیش‌برازش کمک کرد.

اعتبار مدل: همگرایی منحنی‌های یادگیری و تابع هزینه اثبات کرد که مدل پیشنهادی دارای تعمیم‌پذیری بالا (*Generalization*) بوده و برای داده‌های جدید قابل اعتماد است.

SVM Analysis

Accuracy: 0.9376

Cost: 0.1679

Logistic Regression

Accuracy: 0.9315

Cost: 0.2124